

Sprint I - Kanban da Primeira Semana

Projeto: Sistema de busca de informacoes de pesquisadores baseado em Full-Text Search e LLM

Sprint: I - Projeto

Duracao: 1 semana, de quarta-feira a quarta-feira

Descricao Completa do Projeto

Contexto

Universidades, grupos de pesquisa e gestores academicos precisam consultar informacoes sobre pesquisadores, producoes scientificas, areas de atuacao e competencias institucionais. Essas informacoes normalmente estao distribuidas em curriculos Lattes, bases externas e documentos em formatos diferentes, o que dificulta a busca, a analise e a tomada de decisao.

O Curriculo Lattes e uma fonte rica de dados academicos, mas seus arquivos em XML precisam passar por um processo de extracao, transformacao e carga para se tornarem uteis em consultas estruturadas, buscas textuais, buscas semanticas e paineis analiticos. O projeto proposto resolve esse problema criando uma solucao integrada que transforma dados brutos de pesquisadores em informacoes pesquisaveis e analisaveis.

Objetivo do Projeto

O objetivo do projeto e desenvolver um sistema de busca de informacoes de pesquisadores baseado em Full-Text Search e LLM, integrando Ciencia de Dados, Inteligencia Artificial Generativa, banco de dados relacional, banco vetorial, API REST, interface web e visualizacao analitica.

O sistema devera permitir que usuarios pesquisem pesquisadores e producoes scientificas por termos textuais e por similaridade semantica, oferecendo resultados organizados em uma interface web. Alem disso, devera gerar arquivos CSV para analises em ferramenta OLAP, especialmente Power BI.

O Que Sera Feito

O projeto sera desenvolvido em camadas, seguindo o processo Scrum em sprints semanais. A solucao contemplara:

- Orquestracao de dados com Apache Hop para extrair informacoes dos curriculos Lattes em XML.
- Transformacao e carga dos dados em uma base relacional PostgreSQL.
- Modelagem de dados para pesquisadores, producoes scientificas, curriculos, areas, palavras-chave e dados analiticos.
- Criacao de uma base vetorial com pgvector para armazenar embeddings dos titulos das producoes scientificas.
- Desenvolvimento de uma camada de back-end em Python, expondo uma API REST em JSON.
- Implementacao de busca textual usando recursos de Full-Text Search do PostgreSQL.
- Implementacao de busca semantica usando embeddings e tecnicas de IA Generativa.
- Criacao de uma camada de front-end em Next.js para consulta, filtros e visualizacao dos resultados.
- Geracao de arquivos CSV analiticos para construcao de paineis no Power BI.
- Elaboracao de documentacao tecnica com requisitos, historias de usuario, criterios de aceitacao, casos de uso, arquitetura, modelo de dados, documentacao da API e registros do processo Scrum.

Produto Esperado

Ao final do projeto, espera-se entregar um software funcional composto por pipeline de ETL, banco de dados, back-end, front-end e camada analitica. Tambem sera entregue um relatorio tecnico contendo a especificacao completa do produto e os registros de conducao do processo Scrum.

O produto devera demonstrar que os dados dos curriculos Lattes podem ser organizados em uma base relacional, enriquecidos com representacoes vetoriais, pesquisados por texto e por semantica, consumidos por uma interface web e utilizados para analises gerenciais.

Usuarios e Beneficiarios

Os principais usuarios e beneficiarios do sistema sao:

- Pesquisadores que desejam localizar producoes, temas e possiveis colaboradores.
- Professores e orientadores que precisam mapear competencias academicas.
- Gestores universitarios que precisam analisar producao cientifica por pesquisador, periodo ou area.
- Alunos e membros de projetos academicos que desejam consultar linhas de pesquisa e producoes relacionadas a determinados assuntos.

Escopo Inicial

O escopo inicial do projeto considera os dados do Curriculo Lattes como fonte principal. A primeira versao da solucao tera foco em producoes scientificas, pesquisadores, busca textual, busca semantica e geracao de dados analiticos. Integracoes com outras bases, como Qualis CAPES, DOI, grupos de pesquisa ou JCR, poderao ser tratadas como evolucao do projeto conforme disponibilidade de tempo e validacao do professor.

Definicao das Sprints

O projeto sera organizado em cinco sprints principais:

- Sprint I - Projeto: construcao do Product Backlog, analise e especificacao do projeto, historias de usuario, criterios de aceitacao, casos de uso, projeto arquitetural, prototipo de media fidelidade e modelo entidade-relacionamento.
- Sprint II - Camada de Orquestracao de Dados: criacao dos fluxos de ETL com Apache Hop para processar XML do Curriculo Lattes e carregar dados no PostgreSQL.
- Sprint III - Camada de Back-End: desenvolvimento da API REST em Python, busca textual, busca semantica, integracao com pgvector e documentacao da API.
- Sprint IV - Camada de Front-End: desenvolvimento da interface web em Next.js para consumir a API, aplicar filtros e exibir pesquisadores e producoes.
- Sprint V - Camada Analitica e Apresentacao Final: geracao de CSVs analiticos, criacao de painel no Power BI, video demonstrativo, artigo explicativo e apresentacao final dos artefatos.

Sprint Goal: entregar os artefatos de analise e especificacao do produto, com backlog priorizado, requisitos, casos de uso, arquitetura, prototipo de media fidelidade e modelo entidade-relacionamento validados pela equipe.

Definicao de Pronto da Sprint

Um item so deve ir para **Done** quando:

- O artefato estiver registrado no Git.
- O item tiver pelo menos uma evidencia objetiva: arquivo, imagem, link, diagrama ou ata.
- Os criterios de aceitacao estiverem atendidos.
- A equipe tiver revisado o conteudo.
- O material estiver pronto para apresentacao de 10 minutos.

Quadro Kanban

To Do

ID	Item	Tipo	Prioridade	Estimativa	Critérios de aceitacao
KAN-01	Criar repositorio Git e estrutura inicial de pastas	Tarefa tecnica	Alta	2h	Repositorio criado; pastas docs , prototipo , modelagem , scrum e referencias criadas; README inicial descrevendo o projeto
KAN-02	Registrar visao do produto	Documentacao	Alta	2h	Documento descreve problema, objetivo, publico-alvo, principais usuarios e valor do sistema
KAN-03	Construir Product Backlog inicial	Scrum	Alta	3h	Backlog contem epicos, historias de usuario, prioridades e estimativas iniciais
KAN-04	Definir Sprint Backlog da Sprint I	Scrum	Alta	1h	Itens selecionados para a semana; sprint goal documentado; tarefas tecnicas quebradas
KAN-05	Fazer Planning Poker dos itens da Sprint I	Scrum	Alta	1h	Registro das estimativas; divergencias anotadas; estimativa final por item
KAN-06	Especificar historias de usuario com criterios de aceitacao	Requisitos	Alta	5h	Historias cobrem ETL, busca textual, busca semantica, API, frontend e dados analiticos; cada historia tem criterios de aceitacao
KAN-07	Criar diagrama de casos de uso	Modelagem	Alta	3h	Atores principais identificados; casos de uso representam consulta, filtro, busca, carga de dados e exportacao CSV
KAN-08	Criar descricao textual dos casos de uso principais	Modelagem	Media	4h	Pelo menos 4 casos de uso descritos com fluxo principal, pre-condicoes e pos-condicoes
KAN-09	Criar projeto arquitetural da solucao	Arquitetura	Alta	4h	Diagrama mostra Apache Hop, PostgreSQL/pgvector, backend Python, API REST, frontend Next.js e Power BI
KAN-10	Modelar esquema entidade-relacionamento inicial	Banco de dados	Alta	4h	Modelo inclui pesquisadores, producoes, curriculos, palavras-chave/areas e relacionamentos essenciais
KAN-11	Definir estrategia para dados vetoriais	Arquitetura	Media	2h	Documento indica quais textos geram embeddings, onde serao armazenados e como a busca semantica sera feita
KAN-12	Criar prototipo de media fidelidade	UX/UI	Alta	5h	Prototipo mostra tela de busca, filtros, resultado de pesquisadores, detalhe de producoes e area de relatorios
KAN-13	Criar quadro de burndown da Sprint I	Scrum	Media	1h	Grafico ou planilha com total estimado, dias da sprint e trabalho restante
KAN-14	Definir roteiro da apresentacao da Sprint I	Apresentacao	Media	2h	Roteiro de 10 minutos cobrindo backlog, kanban, planning poker, burndown e artefatos
KAN-15	Revisar e consolidar entrega da Sprint I	Qualidade	Alta	3h	Checklist final preenchido; arquivos organizados; pendencias registradas para a proxima sprint

Doing

ID	Item	Responsavel	Observacao
-	-	-	Mover para esta coluna quando alguem iniciar a tarefa

Review

ID	Item	Responsavel pela revisao	Criterio de revisao
-	-	-	Validar clareza, completude e aderencia ao escopo do PDF

Done

ID	Item	Evidencia
-	-	-

Product Backlog Inicial

Prioridade	Epico	Historia de usuario	Valor esperado
1	ETL Lattes	Como administrador, quero carregar curriculos Lattes em XML para uma base relacional, para manter dados estruturados dos pesquisadores	Base confiavel para consultas e relatorios
2	Consulta textual	Como usuario, quero pesquisar producoes cientificas por termos nos titulos, para encontrar pesquisadores e trabalhos relacionados a um tema	Busca objetiva por palavras-chave
3	Busca semantica	Como usuario, quero fazer busca semantica sobre titulos de producoes, para encontrar resultados mesmo quando os termos nao forem identicos	Melhor recuperacao de informacao
4	API REST	Como frontend, quero consumir dados por uma API JSON, para separar interface e backend	Integracao limpa entre camadas
5	Interface Web	Como usuario, quero uma interface em Next.js para buscar pesquisadores, aplicar filtros e visualizar producoes	Experiencia de consulta acessivel
6	Dados analiticos	Como professor/gestor, quero arquivos CSV para Power BI, para analisar producao por ano, pesquisador e periodo quadrienal	Suporte a analises e dashboards
7	Documentacao	Como equipe, quero documentar requisitos, arquitetura e API, para facilitar validacao e continuidade do projeto	Reducao de ambiguidades

Historias de Usuario Prioritarias para Especificacao

HU-01 - Cadastrar dados de pesquisadores via ETL

Como administrador do sistema, quero importar arquivos XML do Curriculo Lattes para o banco relacional, para disponibilizar dados estruturados dos pesquisadores.

Critérios de aceitacao:

- Dado um XML valido do Lattes, quando o pipeline for executado, entao os dados do pesquisador devem ser gravados no banco.
- O sistema deve registrar producoes cientificas associadas ao pesquisador.
- O processo deve evitar duplicidade basica de pesquisadores e producoes.

HU-02 - Buscar producoes por texto

Como usuario, quero buscar producoes cientificas por termos textuais, para encontrar trabalhos relacionados ao tema pesquisado.

Critérios de aceitação:

- A busca deve considerar o título das produções.
- O resultado deve listar título, ano, pesquisador e tipo de produção.
- O usuário deve conseguir combinar busca textual com filtros básicos.

HU-03 - Buscar produções semanticamente

Como usuário, quero realizar busca semântica nos títulos das produções, para encontrar resultados relacionados ao sentido da consulta.

Critérios de aceitação:

- O sistema deve gerar embeddings para os títulos das produções.
- O sistema deve armazenar os vetores no PostgreSQL com pgvector.
- A API deve retornar resultados ordenados por similaridade.

HU-04 - Consultar perfil do pesquisador

Como usuário, quero visualizar o perfil de um pesquisador e suas produções, para entender suas áreas de atuação.

Critérios de aceitação:

- A tela deve exibir nome, identificador, áreas ou palavras-chave disponíveis e lista de produções.
- A lista de produções deve permitir filtragem por ano ou tipo.
- A API deve ter endpoint para listar produções de um pesquisador.

HU-05 - Gerar dados analíticos em CSV

Como professor ou gestor, quero gerar CSVs analíticos, para construir painéis no Power BI.

Critérios de aceitação:

- O backend deve gerar dimensões de pesquisador e tempo.
- O backend deve gerar fato de produção científica.
- Os arquivos devem ser compatíveis com importação no Power BI.

Sugestão de Distribuição Semanal

Dia	Foco	Entregas esperadas
Quarta-feira	Sprint Planning	Sprint goal, backlog selecionado, kanban inicial e planning poker
Quinta-feira	Requisitos	Visão do produto, histórias de usuário e critérios de aceitação
Sexta-feira	Modelagem funcional	Casos de uso e descrições textuais
Sábado	Arquitetura e banco	Diagrama arquitetural, modelo ER e estratégia pgvector
Domingo	Protótipo	Telas principais do protótipo de média fidelidade
Segunda-feira	Revisão integrada	Ajustes nos artefatos, validação interna e burndown atualizado
Terça-feira	Preparação da apresentação	Roteiro de 10 minutos, checklist final e ensaio
Quarta-feira	Sprint Review e Retrospective	Apresentação ao professor, validação e melhorias para Sprint II

Registro de Daily Scrum

Usar este modelo diariamente:

Data	Participantes	O que foi feito ontem	O que sera feito hoje	Impedimentos	Atualizacao do kanban
-	-	-	-	-	-

Planning Poker

Escala sugerida: 1, 2, 3, 5, 8, 13 pontos.

Item	Estimativas individuais	Estimativa final	Observacao
KAN-01	-	1	Estrutura simples do projeto
KAN-02	-	2	Exige alinhamento conceitual
KAN-03	-	3	Base para as demais sprints
KAN-04	-	1	Depende do backlog
KAN-05	-	1	Registro do processo Scrum
KAN-06	-	5	Requer detalhamento dos requisitos
KAN-07	-	3	Diagrama funcional
KAN-08	-	3	Descrição dos fluxos principais
KAN-09	-	5	Integra várias tecnologias
KAN-10	-	5	Define a base das próximas sprints
KAN-11	-	2	Decisão técnica inicial
KAN-12	-	5	Protótipo com múltiplas telas
KAN-13	-	1	Planilha ou gráfico simples
KAN-14	-	2	Organização da apresentação
KAN-15	-	3	Revisão e consolidação

Total estimado: 42 pontos.

Burndown da Sprint I

Dia	Pontos planejados restantes	Pontos reais restantes
Quarta-feira	42	42
Quinta-feira	35	-
Sexta-feira	28	-
Sabado	21	-

Dia	Pontos planejados restantes	Pontos reais restantes
Domingo	14	-
Segunda-feira	8	-
Terça-feira	3	-
Quarta-feira	0	-

Retrospectiva

Preencher no encerramento da Sprint I:

O que funcionou bem	O que precisa melhorar	Acoes para a Sprint II
-	-	-

Checklist de Entrega da Sprint I

- ☐ Product Backlog publicado.
- ☐ Sprint Backlog publicado.
- ☐ Quadro Kanban atualizado.
- ☐ Planning Poker registrado.
- ☐ Burndown atualizado.
- ☐ Historias de usuario com criterios de aceitacao.
- ☐ Casos de uso.
- ☐ Projeto arquitetural.
- ☐ Modelo entidade-relacionamento.
- ☐ Prototipo de media fidelidade.
- ☐ Ata ou registro das Daily Scrums.
- ☐ Sprint Review preparada.
- ☐ Retrospectiva preparada.